



Data Analytics mit SQL & Python

VON DATEN ZUR ENTSCHEIDUNG

DR. CHIAO-YA CHANG
CHIAOYA.CHANG.TW@GMAIL.COM

Tag 4

Explorative Datenanalyse & Reporting



Ablauf

Tag 4 – Explorative Datenanalyse & Reporting		
09:00–09:30	Wiederholung	Datenaufbereitung & Visualisierung
09:30–10:30	Explorative Datenanalyse (EDA)	Statistische Kennzahlen, Verteilungen, Korrelationen
10:30–11:30	Datenbereinigung	Missing Values, Duplikate, Textformate
11:30–12:10	 Mittagspause	—
12:10–14:00	Zeitreihenanalyse und Trendermittlung	Trends erkennen, SQL + Python
14:00–14:20	 Pause	—
14:20–15:40	Praktische Übung	Mini-Projekt & Präsentation
15:40–16:00	Ergebnisse & Diskussion	Präsentation, Reflexion, Q&A





Tag 4 09:00–09:30

Wiederholung & Einstieg

- Datenaufbereitung
- Visualisierung
- Pandas Recap

Wiederholung & Einstieg

30-minütige Übung mit Fitness-Daten

Die Teilnehmenden sollten jedoch:

- **Google Colab öffnen** und die Datei „Day_4_Data_Analytics_SQL_Python_Exercises.ipynb“ laden
- **Teil A zur Wiederholung von Tag 3 bearbeiten**

Ziel:

- Aktivierung des Vorwissens
- Einstieg in die Arbeit mit realen Daten





Tag 4 09:30–10:30

Explorative Datenanalyse (EDA)

- Statistische Kennzahlen
- Verteilungen
- Korrelationen

Was ist Explorative Datenanalyse?

Descriptive Analytics

Was ist passiert?

→ *EDA beginnt hier*

Diagnostic Analytics

Warum ist es passiert?

→ *EDA hilft auch hier*

Predictive Analytics

Was wird passieren?

→ *Grundlage für ML*

Prescriptive Analytics

Was sollen wir tun?

→ *Business-Empfehlung*

👉 **EDA gehört hauptsächlich zu:** Descriptive & Diagnostic

💡 **Warum ist EDA wichtig?**

- Datenqualität überprüfen
- Ausreißer erkennen
- Muster und Trends entdecken
- Grundlage für alle weiteren Analysen

1. Statistische Kennzahlen

Was sind statistische Kennzahlen?

Statistische Kennzahlen helfen uns, Daten **kurz und verständlich zusammenzufassen**.



5 mins

**Mittelwert
(Mean)**
→ Durchschnitt

Median
→ der mittlere
Wert

**Minimum /
Maximum**

**Standardabweic-
hung (Std)**
→ Streuung der
Daten

1. Gegeben sind die Ausgaben von Kunden (€): **50, 60, 55, 65, 70**

 Berechnen Sie:

Mittelwert (Mean) = _____, **Median** = _____

Minimum = _____, **Maximum** = _____

1. Jetzt kommt ein weiterer Kunde(€): **50, 60, 55, 65, 70, 1000**

 Berechnen Sie:

Mittelwert (Mean) = _____, **Median** = _____

Minimum = _____, **Maximum** = _____

 **Wichtiger Hinweis:** Der Durchschnitt kann täuschen!

Beispiel:

Wenn ein Kunde sehr viel ausgibt (Outlier), steigt der Durchschnitt stark an, obwohl die meisten Kunden weniger ausgeben.  Deshalb ist der **Median oft aussagekräftiger**.

2. Verteilungen (Distributions)

Was zeigt uns eine Verteilung?

Wie häufig kommen verschiedene Werte vor – und ob Daten gleichmäßig, schief oder mit Ausreißern verteilt sind.

Normalverteilung

Glockenkurve – Daten symmetrisch um den Mittelwert

Schiefe Verteilung

Werte konzentrieren sich links oder rechts (z. B. Gehälter)

Ausreißer (Outliers)

Extremwerte, die Mittelwert und Analyse verzerren

[>] Visualisierungstools

Histogramm → zeigt Häufigkeiten

Boxplot → Median, Quartile & Ausreißer

[B] Business-Beispiel

E-Commerce: Bestellwerte

Verteilung ist oft rechtsschief:

Wenige Kunden geben sehr viel aus

→ High-Value-Kunden identifizieren

→ Personalisierte Angebote erstellen

3. Korrelationen vs Kausalität

Korrelation misst den statistischen Zusammenhang zwischen zwei Variablen.
Sie bedeutet NICHT, dass A die Ursache von B ist.

+1

Starker positiver
Zusammenhang

0

Kein
Zusammenhang

-1

Starker negativer
Zusammenhang

Klassisches Beispiel

Eisverkauf ↑ → Badeunfälle ↑
Ursache: der Sommer – nicht das Eis!
→ Korrelation ≠ Kausalität

[B] Business-Beispiel

Marketing-Budget ↑ → Umsatz ↑
Ist das wirklich die Ursache?
→ Weitere Faktoren immer prüfen!

Let's Code!

EDA mit dem Job-Posting-Datensatz (Uncleaned_DS_jobs.csv)

```
>> Day_4_Data_Analytics_SQL_Python.ipynb
```

1 Datensatz laden & Struktur prüfen (shape, dtypes, fehlende Werte)

2 Gehaltsverteilung analysieren – Histogramm + Boxplot

3 Top-Bundesstaaten nach Durchschnittsgehalt vergleichen

4 Korrelationsmatrix: Gehalt, Firmen-Rating, Unternehmensalter



*Let's
code!*



Tag 4 10:30–11:30

Datenbereinigung

- Datentabellen

Typische Probleme in Rohdaten

?

Fehlende Werte

NaN, None, leere Zellen

```
df.isna().sum()
```

D

Duplikate

Doppelte Zeilen im Datensatz

```
df.duplicated().sum()
```

F

Unterschiedliche Formate

01.01.2025 vs. 2025-01-01

```
pd.to_datetime(df['datum'])
```

K

Inkonsistente Kategorien

berlin / Berlin / BERLIN

```
df['col'].str.lower().str.strip()
```

T

Falsche Datentypen

Zahlen als Text gespeichert

```
pd.to_numeric(df['col'], errors='coerce')
```


Datenbereinigung



 **Ziel:** Rohdaten in analysierbare, saubere Daten umwandeln – nicht Perfektion, sondern Analysierbarkeit!

Daten verstehen

Fehlende Werte
behandeln

Duplikate
entfernen

Formate
vereinheitlichen

Daten validieren

shape, dtypes
head, describe

dropna()
fillna()

drop_duplicates()


to_numeric
to_datetime

str.lower
str.strip

Business-Beispiel

 Kundendaten:

- „Berlin“, „berlin“, „BERLIN“
→ werden als verschiedene Kategorien gezählt



Let's code!

11:30–12:10 🍴 Mittagspause





Tag 4 12:10–14:00

Zeitreihenanalyse und Trendermittlung

- Grundlegende

Was ist Zeitreihenanalyse?

 Eine Zeitreihe zeigt, wie sich Werte über die Zeit verändern – und lässt uns Muster, Trends und Anomalien erkennen.



Trend

Langfristige Richtung der Daten
(steigend / fallend / stabil)



Saisonalität

Regelmäßig wiederkehrende Muster
(z. B. Weihnachtsgeschäft)



Anomalien

Unerwartete Ausreißer oder
plötzliche Veränderungen

Business-Beispiele: Umsatzentwicklung · Website-Traffic · Mitarbeiteranzahl · Lagerbestand · Aktienkurse

SQL + Python: Das Beste aus beiden Welten

SQL (SQLite)

```
SELECT state,  
       COUNT(*) AS postings,  
       AVG(avg_salary_k)  
FROM jobs  
WHERE avg_salary_k IS NOT NULL  
GROUP BY state  
ORDER BY 3 DESC;
```

Staerken:

Schnelle Aggregationen · Filterung
Verknüpfung mehrerer Tabellen

>>

pd.read
_sql()

Python (Pandas)

```
result = pd.read_sql_query(  
    query, conn)  
  
sns.barplot(  
    data=result.head(10),  
    x='avg_salary_k',  
    y='state')  
plt.show()
```

Staerken:

Visualisierung & Plots
Statistische Berechnungen · ML

Reporting: Von Diagrammen zu Erkenntnissen

 Eine gute Analyse endet nicht mit einem Diagramm – sondern mit einer konkreten Empfehlung.



So what?

Was hat sich verändert?
Zahl + Zeitraum nennen



Context

Verglichen womit?
Benchmark einbeziehen



Recommendation

Was sollen wir konkret tun?
Spezifisch & messbar

KEIN Insight: "Die Daten zeigen, dass Umsätze gestiegen sind." → Beobachtung ohne Empfehlung!
Erst mit Zahl + Benchmark + Empfehlung (R) wird es ein echter Insight.

14:00–14:20 ☕ Pause





Tag 4 14:20–15:40

Mini-Projekt: Exercise

- Gruppenarbeit mit realem Datensatz
- Präsentation (20 - 30 Minuten, 3 - 5 Minuten je Gruppe)

Mini-Projekt: Welche Faktoren beeinflussen Gehälter?

Aufgabe

1. Datensatz laden & bereinigen
2. Gehaltsverteilung analysieren
3. Standort- oder Sektorvergleich
4. Korrelationen untersuchen
5. SQL + Python kombinieren
6. 3 Insights mit SCR formulieren
7. Ergebnisse präsentieren

Notebook

Day_4_Data_Analytics_SQL_Python_Exercises.ipynb
(Teil B: Mini-Projekt)

Leitfragen

- In welchen Bundesstaaten sind Gehälter am höchsten?
- Gibt es einen Zusammenhang zwischen Rating und Gehalt?
- Welche HR-Faktoren hängen mit Fluktuation zusammen?



Tag 4 16:40–17:00

Ergebnisse & Diskussion

- Präsentation
- Reflexion
- Q&A

Das SCR-Framework: So formuliert man Insights

S	So what? <i>Was? Zahl + Zeitraum</i>	Beispiel: <i>„Online-Umsatz stieg in Q4 um 23 % gegenüber Q3“</i>
C	Context <i>Verglichen womit? Benchmark</i>	Beispiel: <i>„Übertrifft Vorjahr um 11 % und Branchenø von 15 %“</i>
R	Recommendation <i>Was tun? Konkret & messbar</i>	Beispiel: <i>„Online-Marketingbudget für Q1 um 20 % erhöhen“</i>

(!) Eine Beobachtung ohne "R" ist KEIN Insight! → Erst mit Empfehlung wird es einer.